

Улучшение оценки нормы разности гессианов для модели смеси экспертов

Игнатъев Даниил и Никита Киселёв
ignatev.daniil@phystech.edu

Аннотация

Модель смеси экспертов (МоЕ) является эффективной архитектурой для масштабирования нейронных сетей, однако её локальные геометрические свойства, в частности структура матрицы Гессе, остаются малоизученными. В данной работе исследуется гаусс-ньютоновская компонента матрицы Гессе для модели МоЕ. Используя подход матрично-представимых сетей, разработанный ранее для полносвязных, сверточных и трансформерных архитектур, мы выводим явную верхнюю оценку спектральной нормы этой компоненты. Оценка выражается через нормы весов экспертов и гейтинга, нормы входных данных и архитектурные параметры (число экспертов, размерности слоев). Полученный результат позволяет анализировать влияние числа экспертов на кривизну поверхности функции потерь и может быть использован для изучения стабилизации ландшафта МоЕ при увеличении объема выборки. Экспериментальная валидация планируется на синтетических данных и задачах классификации.

Ключевые слова: смесь экспертов, матрица Гессе, гаусс-ньютоновское приближение, спектральная норма, матрично-представимые сети.

1 Введение

Модель смеси экспертов (МоЕ) [9, 10] широко применяется для построения больших нейронных сетей благодаря возможности разреженной активации экспертов и эффективного масштабирования. Однако теоретическое понимание свойств оптимизационной поверхности МоЕ, в частности её кривизны, остается ограниченным. Между тем, анализ матрицы Гессе функции потерь играет ключевую роль в изучении сходимости обучения и стабилизации ландшафта при увеличении объема данных [5, 6].

В работах [13, 14] был развит подход к анализу спектральных свойств матрицы Гессе для матрично-представимых нейронных сетей, основанный на разложении Гаусса–Ньютона $\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$ и оценке нормы гаусс-ньютоновской компоненты $\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$. Для полносвязных, сверточных и трансформерных сетей были получены явные верхние оценки $\|\mathbf{G}(\mathbf{w})\|_2$, выраженные через нормы весов, активаций и архитектурные параметры. Данная методология может быть распространена на модель МоЕ, если представить её в виде матрично-представимой сети.

Целью настоящей работы является получение верхней оценки спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для модели смеси экспертов. Такая оценка позволит в дальнейшем использовать её в критериях сходимости ландшафта [13] для МоЕ и анализировать влияние числа экспертов на локальную геометрию поверхности.

2 Постановка задачи

2.1 Модель смеси экспертов

Рассмотрим задачу обучения с учителем, где объект представлен парой $(\mathbf{x}, y)$, $\mathbf{x} \in \mathbb{R}^{d_{\text{in}}}$, $y \in \mathbb{Y}$. Определим **один слой смеси экспертов (МоЕ)**, который в архитектуре трансформера обычно заменяет блок Feed-Forward Network (FFN). Слой состоит из E экспертов и обучаемого гейтинга (роутера). Каждый эксперт представляет собой двухслойную полносвязную сеть с активацией ReLU:

$$\text{FFN}_e(\mathbf{x}) = \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x} + \mathbf{b}_e^{(1)}) + \mathbf{b}_e^{(2)}, \quad e = 1, \dots, E,$$

где $\mathbf{W}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{in}}}$, $\mathbf{b}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}}}$, $\mathbf{W}_e^{(2)} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{ff}}}$, $\mathbf{b}_e^{(2)} \in \mathbb{R}^{d_{\text{out}}}$. Для простоты изложения будем полагать $d_{\text{out}} = d_{\text{in}} = d$ (как в трансформерах) и иногда опускать смещения $\mathbf{b}_e^{(2)}$ без потери общности, так как они не влияют на оценку спектральной нормы весовой части.

Параметры всех экспертов обозначим $\mathbf{w}_{\text{exp}} = (\mathbf{w}_1, \dots, \mathbf{w}_E)$, где $\mathbf{w}_e$ объединяет все веса и смещения e -го эксперта.

Гейтинг (роутер). Мы рассматриваем два варианта, различающихся гладкостью и степенью разреженности.

Гладкий softmax (все эксперты): Классический softmax over all experts:

$$g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^\top \mathbf{x} + b_e)}{\sum_{j=1}^E \exp(\mathbf{a}_j^\top \mathbf{x} + b_j)}, \quad e = 1, \dots, E,$$

где $\mathbf{a}_e \in \mathbb{R}^d$, $b_e \in \mathbb{R}$. Совокупность параметров гейтинга обозначим $\mathbf{w}_g = (\mathbf{a}_1, \dots, \mathbf{a}_E, b_1, \dots, b_E) \in \mathbb{R}^{E(d+1)}$.

Разреженный top-K: Для каждого входа $\mathbf{x}$ вычисляются логиты $s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x} + b_e$. Множество индексов активируемых экспертов $\mathcal{T}(\mathbf{x})$ состоит из K экспертов с наибольшими значениями $s_e(\mathbf{x})$. Веса для выбранных экспертов нормируются softmax:

$$\tilde{g}_e(\mathbf{x}) = \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}, \quad e \in \mathcal{T}(\mathbf{x}); \quad \tilde{g}_e(\mathbf{x}) = 0 \text{ иначе.}$$

Этот вариант не является гладким из-за дискретной операции выбора, однако почти всюду (в областях постоянства $\mathcal{T}(\mathbf{x})$) он дифференцируем.

Архитектура без общего эксперта. Выход МоЕ-слоя формируется как взвешенная сумма выходов экспертов:

$$\mathbf{z} = \sum_{e=1}^E g_e(\mathbf{x}) \text{FFN}_e(\mathbf{x})$$

для варианта с softmax-гейтингом, или с $\tilde{g}_e$ для top-K гейтинга. Полный вектор параметров модели (одного МоЕ-слоя) есть

$$\mathbf{w} = (\mathbf{w}_{\text{exp}}, \mathbf{w}_g),$$

где $\mathbf{w}_{\text{exp}}$ — параметры всех экспертов, $\mathbf{w}_g$ — параметры гейтинга.

Архитектура с общим экспертом. Дополнительно к экспертам вводится общий эксперт $\text{FFN}_{\text{shared}}(\mathbf{x})$,

активируемый для всех входов. Выход слоя принимает вид

$$\mathbf{z} = \text{FFN}_{\text{shared}}(\mathbf{x}) + \sum_{e=1}^E g_e(\mathbf{x}) \text{FFN}_e(\mathbf{x})$$

для softmax-гейтинга (или с $\tilde{g}_e$ для top-K). Параметры общего эксперта обозначим $\mathbf{w}_{\text{shared}}$. Тогда полный вектор параметров

$$\mathbf{w} = (\mathbf{w}_{\text{exp}}, \mathbf{w}_g, \mathbf{w}_{\text{shared}}).$$

2.2 Функция потерь и матрица Гессе

Пусть задана дважды дифференцируемая функция потерь $\ell(\mathbf{z}, y)$ (например, квадратичная потеря или кросс-энтропия). Для одного объекта $(\mathbf{x}, y)$ определим эмпирическую функцию потерь как $\ell(\mathbf{z}(\mathbf{w}), y)$, где $\mathbf{z}(\mathbf{w})$ — выход МоЕ-слоя. Матрица Гессе этой функции по параметрам $\mathbf{w}$ допускает разложение Гаусса–Ньютона [14]:

$$\mathbf{H}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}) + \mathbf{R}(\mathbf{w}),$$

где $\mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{d \times N}$ — якобиан выхода по параметрам, $\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, y) \in \mathbb{R}^{d \times d}$ — матрица кривизны функции потерь по выходу, $\mathbf{R}(\mathbf{w})$ — остаточная компонента, связанная со вторыми производными выхода по параметрам.

Как показано в [13, 14], для анализа локальных свойств ландшафта часто достаточно оценить спектральную норму гаусс-ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

поскольку остаточная компонента $\mathbf{R}(\mathbf{w})$ в окрестности минимума мала или ограничена по норме.

2.3 Предположения

Для получения верхних оценок введём стандартные предположения, аналогичные использованным в диссертации для других архитектур:

1. **Ограниченность входных данных:** $\|\mathbf{x}\|_2 \leq B_x$.
2. **Ограниченность весов:** Для всех экспертов и гейтинга спектральные нормы матриц весов ограничены константой B_W :

$$\|\mathbf{W}_e^{(1)}\|_2, \|\mathbf{W}_e^{(2)}\|_2 \leq B_W, \quad \|\mathbf{a}_e\|_2 \leq B_W \text{ (или аналогично)}.$$

Для смещений $\mathbf{b}$ можно использовать ℓ_2 -норму, но они обычно не влияют на оценку главного члена.

3. **Ограниченность матрицы кривизны потерь:** $\|\mathbf{A}(\mathbf{w})\|_2 \leq M_A$.

4. Для **top-K** гейтинга дополнительно предполагаем, что рассматриваются точки $\mathbf{w}$, в которых множество $\mathcal{T}(\mathbf{x})$ локально постоянно, так что $\tilde{g}_e$ дифференцируемы. Вне этих областей можно использовать субградиентные оценки или гладкую аппроксимацию.

Список литературы

- [1] Vapnik V. N. The Nature of Statistical Learning Theory. – Springer, 1995.
- [2] Kaplan J. et al. Scaling laws for neural language models // arXiv:2001.08361. 2020.
- [3] Hoffmann J. et al. Training compute-optimal large language models // NeurIPS. 2022.
- [4] Li H. et al. Visualizing the loss landscape of neural nets // NeurIPS. 2018.
- [5] Fort S., Ganguli S. Emergent properties of the local geometry of neural loss landscapes // arXiv:1910.05929. 2019.
- [6] Papayan V. Measurements of three-level hierarchical structure in the outliers in the spectrum of deepnet Hessians // ICML. 2019.
- [7] Motrenko A., Strijov V. Sample size estimation for logistic regression using cross-validation and Kullback–Leibler divergence // JMLR. 2014.
- [8] Bishop C. M. Pattern Recognition and Machine Learning. – Springer, 2006.
- [9] Jacobs R. A. et al. Adaptive mixtures of local experts // Neural Computation. 1991.
- [10] Shazeer N. et al. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer // ICLR. 2017.
- [11] Ghorbani B., Krishnan S., Xiao Y. An investigation into neural net optimization via Hessian eigenvalue density // ICML. 2019.
- [12] Granziol D., Zohren S., Roberts S. Hessian Eigenspectra of More Realistic Nonlinear Models // NeurIPS. 2021.
- [13] Kiselev N. S., Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics. 2024.
- [14] Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // ISPRAS Open Conference. 2024.