

Улучшение оценки нормы разности гессианов для модели смеси экспертов

Игнатъев Даниил и Никита Киселёв
ignatev.daniil@phystech.edu

Аннотация

Модель смеси экспертов (МоЕ) является эффективной архитектурой для масштабирования нейронных сетей, однако её локальные геометрические свойства, в частности структура матрицы Гессе, остаются малоизученными. В данной работе исследуется гаусс-ньютоновская компонента матрицы Гессе для модели МоЕ. Используя подход матрично-представимых сетей, разработанный ранее для полносвязных, сверточных и трансформерных архитектур, мы выводим явную верхнюю оценку спектральной нормы этой компоненты. Оценка выражается через нормы весов экспертов и гейтинга, нормы входных данных и архитектурные параметры (число экспертов, размерности слоев). Полученный результат позволяет анализировать влияние числа экспертов на кривизну поверхности функции потерь и может быть использован для изучения стабилизации ландшафта МоЕ при увеличении объема выборки. Экспериментальная валидация планируется на синтетических данных и задачах классификации.

Ключевые слова: смесь экспертов, матрица Гессе, гаусс-ньютоновское приближение, спектральная норма, матрично-представимые сети.

1 Введение

Модель смеси экспертов (Mixture of Experts, MoE) [1, 2, 7] широко применяется для построения больших нейронных сетей благодаря возможности разреженной активации экспертов, эффективного масштабирования и снижения вычислительных затрат при увеличении числа параметров. Однако теоретическое понимание свойств оптимизационной поверхности МоЕ, в частности её кривизны, остаётся ограниченным. Между тем, анализ матрицы Гессе функции потерь играет ключевую роль в изучении сходимости обучения и стабилизации ландшафта при увеличении объема данных [3, 4].

В работах [5, 6] был развит подход к анализу спектральных свойств матрицы Гессе для матрично-представимых нейронных сетей, основанный на разложении Гаусса–Ньютона $\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$ и оценке нормы гаусс-ньютоновской компоненты $\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$. Для полносвязных, сверточных и трансформерных сетей были получены явные верхние оценки $\|\mathbf{G}(\mathbf{w})\|_2$, выраженные через нормы весов, активаций и архитектурные параметры. Данная методология может быть распространена на модель МоЕ, если представить её в виде матрично-представимой сети.

Особый интерес представляют разреженные варианты маршрутизации, при которых для каждого входа активируется только подмножество экспертов. Именно такие механизмы используются в современных sparse MoE-архитектурах, например в Mixtral [8]. Поэтому наряду с полным softmax-гейтингом важно рассмотреть и его разреженные модификации, возникающие после top- K -отбора экспертов.

Целью настоящей работы является получение явной верхней оценки спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для одного слоя смеси экспертов с softmax-гейтингом и связанных с ним разреженных вариантов маршрутизации. Такая оценка позволит в дальнейшем использовать критерии сходимости ландшафта [5] для МоЕ-архитектур и анализировать влияние числа экспертов и схемы маршрутизации на локальную геометрию поверхности функции потерь.

2 Постановка задачи

2.1 Модель смеси экспертов

Рассмотрим задачу обучения с учителем, где объект представлен парой $(\mathbf{x}, y)$, $\mathbf{x} \in \mathbb{R}^{d_{\text{in}}}$, $y \in \mathbb{Y}$. Определим **один слой смеси экспертов (МоЕ)**, который в архитектуре трансформера обычно заменяет блок Feed-Forward Network (FFN). Слой состоит из E экспертов и обучаемого гейтинга (роутера). Каждый эксперт представляет собой двухслойную полносвязную сеть с активацией ReLU:

$$\text{FFN}_e(\mathbf{x}) = \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)}\mathbf{x} + \mathbf{b}_e^{(1)}) + \mathbf{b}_e^{(2)}, \quad e = 1, \dots, E,$$

где $\mathbf{W}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{in}}}$, $\mathbf{b}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}}}$, $\mathbf{W}_e^{(2)} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{ff}}}$, $\mathbf{b}_e^{(2)} \in \mathbb{R}^{d_{\text{out}}}$. Для простоты будем полагать $d_{\text{out}} = d_{\text{in}} = d$, как в стандартных трансформерных блоках.

Параметры всех экспертов обозначим $\mathbf{w}_{\text{exp}} = (\mathbf{w}_1, \dots, \mathbf{w}_E)$, где $\mathbf{w}_e$ объединяет все веса и смещения e -го эксперта.

Гейтинг (роутер). Рассмотрим три варианта маршрутизации, различающихся гладкостью и степенью разреженности.

1. *Полный softmax по всем экспертам.* Классический роутер имеет вид

$$g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^\top \mathbf{x} + b_e)}{\sum_{j=1}^E \exp(\mathbf{a}_j^\top \mathbf{x} + b_j)}, \quad e = 1, \dots, E,$$

где $\mathbf{a}_e \in \mathbb{R}^d$, $b_e \in \mathbb{R}$. Совокупность параметров роутера обозначим через

$$\mathbf{w}_g = (\mathbf{a}_1, \dots, \mathbf{a}_E, b_1, \dots, b_E) \in \mathbb{R}^{E(d+1)}.$$

2. *Топ- K по логитам с softmax-перенормировкой на активном множестве.* Для каждого входа $\mathbf{x}$ вычисляются логиты

$$s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x} + b_e, \quad e = 1, \dots, E,$$

и множество активных экспертов $\mathcal{T}(\mathbf{x})$ состоит из K индексов, соответствующих наибольшим значениям $s_e(\mathbf{x})$. Тогда коэффициенты гейтинга задаются формулой

$$\tilde{g}_e(\mathbf{x}) = \begin{cases} \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}, & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases}$$

3. *Топ- K после полного softmax без дополнительной перенормировки.* В этом случае сначала вы-

числяются коэффициенты $g_e(\mathbf{x})$ полного softmax, после чего сохраняются только K наибольших коэффициентов:

$$\hat{g}_e(\mathbf{x}) = \begin{cases} g_e(\mathbf{x}), & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases}$$

Первые два варианта совпадают после перенормировки на активном множестве, поскольку softmax сохраняет порядок координат. Третий вариант отличается тем, что сумма активных коэффициентов, вообще говоря, меньше единицы.

Архитектура без общего эксперта. Выход МоЕ-слоя формируется как взвешенная сумма выходов экспертов:

$$\mathbf{z} = \sum_{e=1}^E \gamma_e(\mathbf{x}) \text{FFN}_e(\mathbf{x}),$$

где γ_e обозначает один из рассмотренных выше вариантов гейтинга. Полный вектор параметров модели имеет вид

$$\mathbf{w} = (\mathbf{w}_{\text{exp}}, \mathbf{w}_g).$$

В теоретической части ниже для краткости все смещения в экспертных и роутерных блоках опускаются. Это упрощает записи, но не меняет структуры доказательств и порядка получаемых оценок.

2.2 Функция потерь и матрица Гессе

Пусть задана дважды дифференцируемая функция потерь $\ell(\mathbf{z}, y)$ (например, квадратичная потеря или кросс-энтропия). Для одного объекта $(\mathbf{x}, y)$ определим эмпирическую функцию потерь как $\ell(\mathbf{z}(\mathbf{w}), y)$, где $\mathbf{z}(\mathbf{w})$ — выход МоЕ-слоя. Матрица Гессе этой функции по параметрам $\mathbf{w}$ допускает разложение Гаусса–Ньютона [6]:

$$\mathbf{H}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}) + \mathbf{R}(\mathbf{w}),$$

где $\mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{d \times N}$ — якобиан выхода по параметрам, $\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, y) \in \mathbb{R}^{d \times d}$ — матрица кривизны функции потерь по выходу, $\mathbf{R}(\mathbf{w})$ — остаточная компонента, связанная со вторыми производными выхода по параметрам.

Как показано в [5, 6], для анализа локальных свойств ландшафта часто достаточно оценить спектральную норму гаусс–ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

поскольку остаточная компонента $\mathbf{R}(\mathbf{w})$ в окрестности минимума мала или ограничена по норме.

3 Теоретическая часть

3.1 Матрично-представимое представление МоЕ и факторизация гаусс–ньютоновской компоненты

Для получения явной оценки нормы гаусс–ньютоновской компоненты удобно использовать представление МоЕ-слоя как матрично-представимой нейронной сети.

Определение 1. Нейронная сеть называется *матрично-представимой*, если ее выход $\mathbf{z} = f_{\mathbf{w}}(\mathbf{x})$ для входа $\mathbf{x}$ может быть записан в виде

$$\mathbf{x}^{(1)} = \mathbf{x}, \quad \mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)}), \quad \mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)}), \quad p = 1, \dots, L-1,$$

$$\mathbf{z} = \mathbf{z}^{(L)} = T_{\mathbf{w}^{(L)}}^{(L)}(\mathbf{x}^{(L)}),$$

где $\mathbf{w} = \text{col}(\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(L)})$, а каждый оператор $T_{\mathbf{w}^{(p)}}^{(p)} : \mathbb{R}^{n_{p-1}} \rightarrow \mathbb{R}^{n_p}$ линеен по входу $\mathbf{x}^{(p)}$.

Для каждого слоя введем матрицу распространения возмущения преактивации к выходу сети

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}}$$

и параметрический якобиан слоя

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}}.$$

Лемма 1. Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью. Тогда якобиан выхода сети по параметрам p -го слоя факторизуется в виде

$$\mathbf{J}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}^{(p)}} = \mathbf{S}^{(p)}(\mathbf{w}) \mathbf{P}^{(p)}(\mathbf{w}).$$

Следовательно,

$$\mathbf{J}(\mathbf{w}) = [\mathbf{S}^{(1)}(\mathbf{w}) \mathbf{P}^{(1)}(\mathbf{w}), \dots, \mathbf{S}^{(L)}(\mathbf{w}) \mathbf{P}^{(L)}(\mathbf{w})].$$

Доказательство. Утверждение следует из правила дифференцирования сложной функции и блочной структуры вектора параметров $\mathbf{w}$. $\square$

Лемма 2. Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью, а

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^{\top} \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$$

есть гаусс—ньютоновская компонента матрицы Гессе. Тогда $\mathbf{G}(\mathbf{w})$ имеет блочную структуру

$$\mathbf{G}(\mathbf{w}) = [\mathbf{G}^{(p,q)}(\mathbf{w})]_{p,q=1}^L, \quad \mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^{\top} \mathbf{S}^{(p)}(\mathbf{w})^{\top} \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)}(\mathbf{w}) \mathbf{P}^{(q)}(\mathbf{w}).$$

Доказательство. Подстановка факторизации из леммы 1 в определение $\mathbf{G}(\mathbf{w})$ дает требуемое блочное представление. $\square$

3.2 Оценка гаусс—ньютоновской компоненты для МоЕ с softmax-гейтингом

Рассмотрим один слой смеси экспертов без смещений:

$$\mathbf{z} = \sum_{e=1}^E g_e(\mathbf{x}) \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}), \quad (1)$$

где коэффициенты гейтинга определяются формулой

$$g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^{\top} \mathbf{x})}{\sum_{j=1}^E \exp(\mathbf{a}_j^{\top} \mathbf{x})}, \quad e = 1, \dots, E. \quad (2)$$

Ниже смещения в экспертных и роутерных блоках опускаются для краткости. Их учет не меняет структуру доказательств и порядок получаемых оценок.

Введем обозначения

$$\mathbf{u}_e = \mathbf{W}_e^{(1)} \mathbf{x}, \quad \mathbf{r}_e = \text{ReLU}(\mathbf{u}_e), \quad \mathbf{s} = \mathbf{B} \mathbf{x}, \quad \mathbf{B} = \begin{bmatrix} \mathbf{a}_1^\top \\ \vdots \\ \mathbf{a}_E^\top \end{bmatrix} \in \mathbb{R}^{E \times d}$$

Лемма 3. Модель (1)–(2) является матрично-представимой нейронной сетью глубины $L = 2$.

Доказательство. Положим

$$\mathbf{z}^{(1)} = \begin{bmatrix} \mathbf{W}_1^{(1)} \mathbf{x} \\ \vdots \\ \mathbf{W}_E^{(1)} \mathbf{x} \\ \mathbf{B} \mathbf{x} \end{bmatrix} \in \mathbb{R}^{Ed_{\text{ff}} + E}$$

и определим нелинейность

$$\sigma_{\text{MoE}} \left(\begin{bmatrix} \mathbf{u}_1 \\ \vdots \\ \mathbf{u}_E \\ \mathbf{s} \end{bmatrix} \right) = \begin{bmatrix} g_1(\mathbf{s}) \text{ReLU}(\mathbf{u}_1) \\ \vdots \\ g_E(\mathbf{s}) \text{ReLU}(\mathbf{u}_E) \\ \mathbf{s} \end{bmatrix} = \mathbf{x}^{(2)},$$

где $g_e(\mathbf{s}) = \exp(s_e) / \sum_{j=1}^E \exp(s_j)$. Тогда

$$\mathbf{z} = \begin{bmatrix} \mathbf{W}_1^{(2)} & \dots & \mathbf{W}_E^{(2)} & \mathbf{0}_{d \times E} \end{bmatrix} \mathbf{x}^{(2)},$$

то есть модель является матрично-представимой сетью глубины $L = 2$. □

В силу леммы 3

$$\mathbf{J}(\mathbf{w}) = [\mathbf{J}^{(1)}(\mathbf{w}), \mathbf{J}^{(2)}(\mathbf{w})] = [\mathbf{S}^{(1)}(\mathbf{w}) \mathbf{P}^{(1)}(\mathbf{w}), \mathbf{S}^{(2)}(\mathbf{w}) \mathbf{P}^{(2)}(\mathbf{w})].$$

Теорема 1. Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1)–(2). Предположим, что существуют положительные константы $M_{\mathbf{x}}, M_{\mathbf{A}}, M_1, M_2$ такие, что

$$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}, \quad \|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}, \quad \|\mathbf{W}_e^{(1)}\|_2 \leq M_1, \quad \|\mathbf{W}_e^{(2)}\|_2 \leq M_2, \quad e = 1, \dots, E. \quad (3)$$

Обозначим $S_g(\mathbf{x}) = \sum_{e=1}^E g_e(\mathbf{x})^2$. Тогда для гаусс–ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 S_g(\mathbf{x}) (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (4)$$

Доказательство. Для краткости пишем $g_e = g_e(\mathbf{s}) = g_e(\mathbf{x})$, $S_g = S_g(\mathbf{x})$.

Оценка $\mathbf{P}^{(1)}(\mathbf{w})$. Пусть

$$\mathbf{w}^{(1)} = \text{col}(\mathbf{W}_1^{(1)}, \dots, \mathbf{W}_E^{(1)}, \mathbf{a}_1, \dots, \mathbf{a}_E).$$

Тогда для произвольного приращения $\Delta \mathbf{w}^{(1)}$ имеем

$$\mathbf{P}^{(1)}(\mathbf{w})\Delta \mathbf{w}^{(1)} = \begin{bmatrix} \Delta \mathbf{W}_1^{(1)} \mathbf{x} \\ \vdots \\ \Delta \mathbf{W}_E^{(1)} \mathbf{x} \\ \Delta \mathbf{B} \mathbf{x} \end{bmatrix}, \quad \Delta \mathbf{B} = \begin{bmatrix} \Delta \mathbf{a}_1^\top \\ \vdots \\ \Delta \mathbf{a}_E^\top \end{bmatrix}.$$

Следовательно,

$$\|\mathbf{P}^{(1)}(\mathbf{w})\Delta \mathbf{w}^{(1)}\|_2^2 = \sum_{e=1}^E \|\Delta \mathbf{W}_e^{(1)} \mathbf{x}\|_2^2 + \|\Delta \mathbf{B} \mathbf{x}\|_2^2 \leq \|\mathbf{x}\|_2^2 \left(\sum_{e=1}^E \|\Delta \mathbf{W}_e^{(1)}\|_F^2 + \|\Delta \mathbf{B}\|_F^2 \right) = \|\mathbf{x}\|_2^2 \|\Delta \mathbf{w}^{(1)}\|_2^2.$$

Отсюда $\|\mathbf{P}^{(1)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}}$.

Оценка $\mathbf{P}^{(2)}(\mathbf{w})$. Поскольку

$$\mathbf{x}^{(2)} = \begin{bmatrix} g_1 \mathbf{r}_1 \\ \vdots \\ g_E \mathbf{r}_E \\ \mathbf{s} \end{bmatrix},$$

а последние E координат умножаются на нулевой блок, имеем $\mathbf{P}^{(2)}(\mathbf{w})\Delta \mathbf{w}^{(2)} = \sum_{e=1}^E \Delta \mathbf{W}_e^{(2)}(g_e \mathbf{r}_e)$. Для оператора $(\Delta \mathbf{W}_1^{(2)}, \dots, \Delta \mathbf{W}_E^{(2)}) \mapsto \sum_{e=1}^E \Delta \mathbf{W}_e^{(2)}(g_e \mathbf{r}_e)$ по неравенству Коши–Буняковского

$$\left\| \sum_{e=1}^E \Delta \mathbf{W}_e^{(2)}(g_e \mathbf{r}_e) \right\|_2 \leq \left(\sum_{e=1}^E \|\Delta \mathbf{W}_e^{(2)}\|_F^2 \right)^{1/2} \left(\sum_{e=1}^E g_e^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2}.$$

Неравенство достигается выбором приращений, направленных вдоль векторов $g_e \mathbf{r}_e$, поэтому

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e=1}^E g_e^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2}.$$

Так как $\|\mathbf{r}_e\|_2 \leq \|\mathbf{u}_e\|_2 \leq \|\mathbf{W}_e^{(1)}\|_2 \|\mathbf{x}\|_2 \leq M_1 M_{\mathbf{x}}$, получаем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}} \sqrt{S_g}.$$

Оценка $\mathbf{S}^{(2)}(\mathbf{w})$. Так как $\mathbf{z} = \mathbf{z}^{(2)}$, имеем $\mathbf{S}^{(2)}(\mathbf{w}) = \mathbf{I}_d$, и $\|\mathbf{S}^{(2)}(\mathbf{w})\|_2 = 1$.

Оценка $\mathbf{S}^{(1)}(\mathbf{w})$. Рассмотрим отображение $\mathbf{z} = F(\mathbf{z}^{(1)})$, где

$$\mathbf{z}^{(1)} = \begin{bmatrix} \mathbf{u}_1 \\ \vdots \\ \mathbf{u}_E \\ \mathbf{s} \end{bmatrix}.$$

Будем оценивать действие его производной на произвольное направление $\Delta \mathbf{z}^{(1)} = \text{col}(\Delta \mathbf{u}_1, \dots, \Delta \mathbf{u}_E, \Delta \mathbf{s})$.

Иными словами,

$$\Delta \mathbf{z} = DF(\mathbf{z}^{(1)})[\Delta \mathbf{z}^{(1)}] = \lim_{\varepsilon \rightarrow 0} \frac{F(\mathbf{z}^{(1)} + \varepsilon \Delta \mathbf{z}^{(1)}) - F(\mathbf{z}^{(1)})}{\varepsilon}.$$

Поскольку $DF(\mathbf{z}^{(1)}) = \mathbf{S}^{(1)}(\mathbf{w})$, из равномерной по всем направлениям оценки $\|\Delta \mathbf{z}\|_2 \leq C \|\Delta \mathbf{z}^{(1)}\|_2$ следует $\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq C$.

Положим $\mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{r}_e$. Тогда

$$\mathbf{z} = \sum_{e=1}^E g_e \mathbf{y}_e.$$

Разложим линейный отклик на две части: $\Delta \mathbf{z} = \Delta \mathbf{z}_{\mathbf{u}} + \Delta \mathbf{z}_{\mathbf{s}}$, где $\Delta \mathbf{z}_{\mathbf{u}}$ соответствует изменению $\mathbf{y}_e$ при фиксированных g_e , а $\Delta \mathbf{z}_{\mathbf{s}}$ соответствует изменению коэффициентов g_e при фиксированных $\mathbf{y}_e$.

Работаем в точках дифференцируемости ReLU. Если некоторая координата $\mathbf{u}_e$ равна нулю, достаточно выбрать любое значение производной ReLU из $[0, 1]$, поскольку ниже используется только оценка $\|\mathbf{D}_e\|_2 \leq 1$.

Для первой части положим $\mathbf{D}_e = \text{diag}(\text{ReLU}'(\mathbf{u}_e))$. Тогда $\Delta \mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e$, $\|\mathbf{D}_e\|_2 \leq 1$, и поэтому

$$\Delta \mathbf{z}_{\mathbf{u}} = \sum_{e=1}^E g_e \Delta \mathbf{y}_e = \sum_{e=1}^E g_e \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e.$$

Следовательно,

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{u}}\|_2 &\leq M_2 \sum_{e=1}^E g_e \|\Delta \mathbf{u}_e\|_2 \\ &\leq M_2 \left(\sum_{e=1}^E g_e^2 \right)^{1/2} \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} = M_2 \sqrt{S_g} \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}. \end{aligned}$$

Для второй части используем формулу производной softmax. Обозначим $\overline{\Delta s} = \sum_{j=1}^E g_j \Delta s_j$. Тогда изменение коэффициентов гейтинга даёт

$$\Delta \mathbf{z}_{\mathbf{s}} = \sum_{e=1}^E g_e (\Delta s_e - \overline{\Delta s}) \mathbf{y}_e.$$

Так как $\|\mathbf{y}_e\|_2 \leq \|\mathbf{W}_e^{(2)}\|_2 \|\mathbf{r}_e\|_2 \leq M_1 M_2 M_{\mathbf{x}}$, получаем

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{s}}\|_2 &\leq M_1 M_2 M_{\mathbf{x}} \sum_{e=1}^E g_e |\Delta s_e - \overline{\Delta s}| \\ &\leq M_1 M_2 M_{\mathbf{x}} \left(\sum_{e=1}^E g_e |\Delta s_e| + |\overline{\Delta s}| \right) \leq 2 M_1 M_2 M_{\mathbf{x}} \sum_{e=1}^E g_e |\Delta s_e| \\ &\leq 2 M_1 M_2 M_{\mathbf{x}} \left(\sum_{e=1}^E g_e^2 \right)^{1/2} \left(\sum_{e=1}^E |\Delta s_e|^2 \right)^{1/2} = 2 M_1 M_2 M_{\mathbf{x}} \sqrt{S_g} \|\Delta \mathbf{s}\|_2. \end{aligned}$$

Обозначив $a = \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}$ и $b = \|\Delta \mathbf{s}\|_2$, получаем $\|\Delta \mathbf{z}\|_2 \leq M_2 \sqrt{S_g} a + 2 M_1 M_2 M_{\mathbf{x}} \sqrt{S_g} b$. По

неравенству Коши–Буняковского $a + 2M_1 M_{\mathbf{x}} b \leq \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2} \sqrt{a^2 + b^2}$. Следовательно,

$$\|\Delta \mathbf{z}\|_2 \leq M_2 \sqrt{S_g} \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2} \|\Delta \mathbf{z}^{(1)}\|_2.$$

Значит,

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{S_g} \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2}.$$

Полученные оценки дают

$$\|\mathbf{J}^{(1)}(\mathbf{w})\|_2 \leq M_2 M_{\mathbf{x}} \sqrt{S_g} \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2}, \quad \|\mathbf{J}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}} \sqrt{S_g}.$$

Поэтому

$$\begin{aligned} \|\mathbf{J}(\mathbf{w})\|_2^2 &\leq \|\mathbf{J}^{(1)}(\mathbf{w})\|_2^2 + \|\mathbf{J}^{(2)}(\mathbf{w})\|_2^2 \\ &\leq M_2^2 M_{\mathbf{x}}^2 S_g (1 + 4M_1^2 M_{\mathbf{x}}^2) + M_1^2 M_{\mathbf{x}}^2 S_g \\ &= M_{\mathbf{x}}^2 S_g (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2). \end{aligned}$$

Так как $\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2$, из (3) следует (4). $\square$

Замечание 1.1. Если в оценке слагаемого, отвечающего за возмущение softmax-коэффициентов, не сохранять зависимость от $S_g(\mathbf{x})$, то можно получить более грубую оценку

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Действительно, по неравенству Коши–Буняковского с весами g_e ,

$$\sum_{e=1}^E g_e |\Delta s_e - \overline{\Delta s}| \leq \sqrt{\left(\sum_{e=1}^E g_e\right) \left(\sum_{e=1}^E g_e (\Delta s_e - \overline{\Delta s})^2\right)} \leq \|\Delta \mathbf{s}\|_2$$

Вторая сумма является взвешенной дисперсией координат Δs_e относительно среднего $\overline{\Delta s} = \sum_{e=1}^E g_e \Delta s_e$, откуда и

$$\sum_{e=1}^E g_e (\Delta s_e - \overline{\Delta s})^2 = \sum_{e=1}^E g_e (\Delta s_e)^2 - (\overline{\Delta s})^2 \leq \sum_{e=1}^E g_e (\Delta s_e)^2 \leq \|\Delta \mathbf{s}\|_2^2.$$

Эта оценка не отражает влияние концентрации гейтинга через $S_g(\mathbf{x})$, но полезна как базовая граница, не зависящая от распределения коэффициентов softmax.

3.3 Следствия для разреженных вариантов softmax-гейтинга

Ниже рассматриваются разреженные варианты маршрутизации, возникающие из softmax-гейтинга. При фиксированном входе $\mathbf{x}$ активное множество определяется параметрами роутера; условие строгого разделения логитов обеспечивает его локальную постоянность в окрестности рассматриваемого параметра $\mathbf{w}$.

Следствие 1.2. Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1), в котором множество активных экспертов состоит из K индексов, соответствующих наибольшим значениям логитов

$s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x}$, а коэффициенты гейтинга задаются формулой

$$\tilde{g}_e(\mathbf{x}) = \begin{cases} \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}, & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases} \quad (5)$$

Предположим, что выполнены условия (3), и обозначим $\tilde{S}_g(\mathbf{x}) = \sum_{e \in \mathcal{T}(\mathbf{x})} \tilde{g}_e(\mathbf{x})^2$. Пусть, кроме того, в рассматриваемой точке выполнено условие строгого разделения

$$s_{(K)}(\mathbf{x}) > s_{(K+1)}(\mathbf{x}), \quad (6)$$

где $s_{(1)}(\mathbf{x}) \geq \dots \geq s_{(E)}(\mathbf{x})$ — логиты роутера, упорядоченные по невозрастанию. Тогда в некоторой окрестности рассматриваемого параметра $\mathbf{w}$ активное множество $\mathcal{T}(\mathbf{x})$ постоянно, и для гаусс–ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 \tilde{S}_g(\mathbf{x}) (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (7)$$

Доказательство. Для краткости пишем $\tilde{g}_e = \tilde{g}_e(\mathbf{x})$, $\tilde{S}_g = \tilde{S}_g(\mathbf{x})$. Условие (6) обеспечивает локальную постоянность активного множества. Зафиксируем это множество и обозначим его через $\mathcal{T}$.

На рассматриваемой окрестности модель имеет вид

$$\mathbf{z} = \sum_{e \in \mathcal{T}} \tilde{g}_e \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}),$$

причём softmax вычисляется только по индексам из $\mathcal{T}$. Поэтому оценки из доказательства теоремы 1 повторяются после замены сумм по $e = 1, \dots, E$ на суммы по $e \in \mathcal{T}$ и коэффициентов g_e на $\tilde{g}_e$.

Оценка для $\mathbf{P}^{(1)}(\mathbf{w})$ не меняется:

$$\|\mathbf{P}^{(1)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}}.$$

Для второго параметрического якобиана имеем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e \in \mathcal{T}} \tilde{g}_e^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2} \leq M_1 M_{\mathbf{x}} \sqrt{\tilde{S}_g}.$$

Также $\|\mathbf{S}^{(2)}(\mathbf{w})\|_2 = 1$.

Осталось оценить $\mathbf{S}^{(1)}(\mathbf{w})$. Как и в доказательстве теоремы 1, рассмотрим направление $\Delta \mathbf{z}^{(1)} = \text{col}(\Delta \mathbf{u}_1, \dots, \Delta \mathbf{u}_E, \Delta \mathbf{s})$ и разложим линейный отклик: $\Delta \mathbf{z} = \Delta \mathbf{z}_{\mathbf{u}} + \Delta \mathbf{z}_{\mathbf{s}}$. Для первой части получаем

$$\Delta \mathbf{z}_{\mathbf{u}} = \sum_{e \in \mathcal{T}} \tilde{g}_e \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e, \quad \|\mathbf{D}_e\|_2 \leq 1,$$

откуда

$$\|\Delta \mathbf{z}_{\mathbf{u}}\|_2 \leq M_2 \sum_{e \in \mathcal{T}} \tilde{g}_e \|\Delta \mathbf{u}_e\|_2 \leq M_2 \left(\sum_{e \in \mathcal{T}} \tilde{g}_e^2 \right)^{1/2} \left(\sum_{e \in \mathcal{T}} \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} \leq M_2 \sqrt{\tilde{S}_g} \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}.$$

Для второй части положим $\mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{r}_e$, тогда $\|\mathbf{y}_e\|_2 \leq M_1 M_2 M_{\mathbf{x}}$. Поскольку softmax вычисляется

на множестве $\mathcal{T}$, обозначим $\overline{\Delta s}_{\mathcal{T}} = \sum_{j \in \mathcal{T}} \tilde{g}_j \Delta s_j$. Тогда $\Delta \mathbf{z}_s = \sum_{e \in \mathcal{T}} \tilde{g}_e (\Delta s_e - \overline{\Delta s}_{\mathcal{T}}) \mathbf{y}_e$. Следовательно,

$$\begin{aligned} \|\Delta \mathbf{z}_s\|_2 &\leq M_1 M_2 M_{\mathbf{x}} \sum_{e \in \mathcal{T}} \tilde{g}_e |\Delta s_e - \overline{\Delta s}_{\mathcal{T}}| \\ &\leq M_1 M_2 M_{\mathbf{x}} \left(\sum_{e \in \mathcal{T}} \tilde{g}_e |\Delta s_e| + |\overline{\Delta s}_{\mathcal{T}}| \right) \\ &\leq 2 M_1 M_2 M_{\mathbf{x}} \sum_{e \in \mathcal{T}} \tilde{g}_e |\Delta s_e| \\ &\leq 2 M_1 M_2 M_{\mathbf{x}} \left(\sum_{e \in \mathcal{T}} \tilde{g}_e^2 \right)^{1/2} \left(\sum_{e \in \mathcal{T}} |\Delta s_e|^2 \right)^{1/2} \\ &\leq 2 M_1 M_2 M_{\mathbf{x}} \sqrt{\tilde{S}_g} \|\Delta \mathbf{s}\|_2. \end{aligned}$$

Тем самым

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{\tilde{S}_g} \sqrt{1 + 4 M_1^2 M_{\mathbf{x}}^2}.$$

Следовательно,

$$\|\mathbf{J}^{(1)}(\mathbf{w})\|_2 \leq M_2 M_{\mathbf{x}} \sqrt{\tilde{S}_g} \sqrt{1 + 4 M_1^2 M_{\mathbf{x}}^2}, \quad \|\mathbf{J}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}} \sqrt{\tilde{S}_g}.$$

Значит,

$$\|\mathbf{J}(\mathbf{w})\|_2^2 \leq M_{\mathbf{x}}^2 \tilde{S}_g (M_1^2 + M_2^2 + 4 M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Используя $\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2^2$ и условие (3), получаем (7). $\square$

Замечание 1.3. Следствие 1.2 охватывает маршрутирование, в котором сначала выбираются top- K логитов роутера, а затем softmax вычисляется только на активном множестве. Такой механизм используется например в Mixtral [8].

Замечание 1.4. Если сначала вычисляется полный softmax по всем экспертам, затем сохраняются top- K коэффициентов и выполняется перенормировка на активном множестве, то получающиеся веса совпадают с (5). Действительно, softmax сохраняет порядок координат, а для $e \in \mathcal{T}(\mathbf{x})$ имеем

$$\frac{g_e(\mathbf{x})}{\sum_{j \in \mathcal{T}(\mathbf{x})} g_j(\mathbf{x})} = \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}.$$

Следовательно, следствие 1.2 покрывает оба эквивалентных варианта: «top- K по логитам, затем softmax на активном множестве» и «полный softmax, затем top- K и перенормировка».

Следствие 1.5. Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1), в котором сначала вычисляются softmax-коэффициенты (2), а затем применяется top- K -отбор без дополнительной перенормировки:

$$\hat{g}_e(\mathbf{x}) = \begin{cases} g_e(\mathbf{x}), & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases} \quad (8)$$

Здесь $\mathcal{T}(\mathbf{x})$ есть множество K индексов, соответствующих наибольшим значениям логитов $s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x}$. Предположим, что выполнены условия (3), и обозначим $\hat{S}_g(\mathbf{x}) = \sum_{e \in \mathcal{T}(\mathbf{x})} g_e(\mathbf{x})^2$. Пусть, кроме того, выполнено условие строгого разделения (6). Тогда в некоторой окрестности рассматриваемого

параметра $\mathbf{w}$ активное множество $\mathcal{T}(\mathbf{x})$ постоянно, и для гаусс—ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 \hat{S}_g(\mathbf{x}) (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (9)$$

Доказательство. Для краткости пишем $g_e = g_e(\mathbf{s}) = g_e(\mathbf{x})$, $\hat{S}_g = \hat{S}_g(\mathbf{x})$. Условие (6) обеспечивает локальную постоянность активного множества. Зафиксируем это множество и обозначим его через $\mathcal{T}$.

На рассматриваемой окрестности модель имеет вид

$$\mathbf{z} = \sum_{e \in \mathcal{T}} g_e \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}).$$

В отличие от следствия 1.2, коэффициенты g_e здесь остаются коэффициентами полного softmax по всем E экспертам.

Оценка для $\mathbf{P}^{(1)}(\mathbf{w})$ не меняется:

$$\|\mathbf{P}^{(1)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}}.$$

Для второго параметрического якобиана имеем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e \in \mathcal{T}} g_e^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2} \leq M_1 M_{\mathbf{x}} \sqrt{\hat{S}_g}.$$

Также $\|\mathbf{S}^{(2)}(\mathbf{w})\|_2 = 1$.

Оценим $\mathbf{S}^{(1)}(\mathbf{w})$. Как и выше, рассмотрим направление $\Delta \mathbf{z}^{(1)} = \text{col}(\Delta \mathbf{u}_1, \dots, \Delta \mathbf{u}_E, \Delta \mathbf{s})$ и разложим линейный отклик: $\Delta \mathbf{z} = \Delta \mathbf{z}_{\mathbf{u}} + \Delta \mathbf{z}_{\mathbf{s}}$.

Для первой части получаем

$$\Delta \mathbf{z}_{\mathbf{u}} = \sum_{e \in \mathcal{T}} g_e \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e, \quad \|\mathbf{D}_e\|_2 \leq 1.$$

Следовательно,

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{u}}\|_2 &\leq M_2 \sum_{e \in \mathcal{T}} g_e \|\Delta \mathbf{u}_e\|_2 \\ &\leq M_2 \left(\sum_{e \in \mathcal{T}} g_e^2 \right)^{1/2} \left(\sum_{e \in \mathcal{T}} \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} \\ &\leq M_2 \sqrt{\hat{S}_g} \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}. \end{aligned}$$

Для второй части положим $\mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{r}_e$. Тогда $\|\mathbf{y}_e\|_2 \leq M_1 M_2 M_{\mathbf{x}}$. Поскольку g_e являются коэффициентами полного softmax, обозначим $\overline{\Delta s} = \sum_{j=1}^E g_j \Delta s_j$. Тогда

$$\Delta \mathbf{z}_{\mathbf{s}} = \sum_{e \in \mathcal{T}} g_e (\Delta s_e - \overline{\Delta s}) \mathbf{y}_e.$$

Значит,

$$\|\Delta \mathbf{z}_{\mathbf{s}}\|_2 \leq M_1 M_2 M_{\mathbf{x}} \sum_{e \in \mathcal{T}} g_e |\Delta s_e - \overline{\Delta s}|.$$

Обозначим $\tau = \sum_{e \in \mathcal{T}} g_e$ и $S_g = \sum_{e=1}^E g_e^2$. Так как $\mathcal{T}$ состоит из индексов с наибольшими коэффициентами softmax, выполнено $\tau^2 S_g \leq \hat{S}_g$. Действительно, для $j \notin \mathcal{T}$ имеем $g_j \leq \hat{S}_g/\tau$, поэтому $S_g \leq \hat{S}_g/\tau$ и, следовательно, $\tau^2 S_g \leq \tau \hat{S}_g \leq \hat{S}_g$.

Теперь

$$\begin{aligned} \sum_{e \in \mathcal{T}} g_e |\Delta s_e - \overline{\Delta s}| &\leq \sum_{e \in \mathcal{T}} g_e |\Delta s_e| + \tau |\overline{\Delta s}| \\ &\leq \sqrt{\hat{S}_g} \|\Delta \mathbf{s}\|_2 + \tau \sqrt{S_g} \|\Delta \mathbf{s}\|_2 \\ &\leq 2\sqrt{\hat{S}_g} \|\Delta \mathbf{s}\|_2. \end{aligned}$$

Отсюда

$$\|\Delta \mathbf{z}_s\|_2 \leq 2M_1 M_2 M_{\mathbf{x}} \sqrt{\hat{S}_g} \|\Delta \mathbf{s}\|_2.$$

Повторяя финальный шаг из доказательства теоремы 1, получаем

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{\hat{S}_g} \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2}.$$

Следовательно,

$$\|\mathbf{J}^{(1)}(\mathbf{w})\|_2 \leq M_2 M_{\mathbf{x}} \sqrt{\hat{S}_g} \sqrt{1 + 4M_1^2 M_{\mathbf{x}}^2}, \quad \|\mathbf{J}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}} \sqrt{\hat{S}_g}.$$

Значит,

$$\|\mathbf{J}(\mathbf{w})\|_2^2 \leq M_{\mathbf{x}}^2 \hat{S}_g (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Используя $\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2^2$ и условие (3), получаем (9). $\square$

4 Вычислительный эксперимент

4.1 Схема «учитель–ученик» на синтетических данных

Для эмпирической проверки использовалась стандартная схема «учитель–ученик». Генерировался **учитель** — слой МоЕ с фиксированными параметрами ($E_{\text{teacher}} = 16$, $d = 16$, $d_{\text{ff}} = 32$, $K = E$, softmax-гейтинг). Входные векторы $\mathbf{x} \in \mathbb{R}^d$ выбирались на единичной сфере; выходы учителя $\mathbf{z}_{\text{teacher}}$ вычислялись без шума. Формировались обучающая (2048 объектов) и тестовая (512 объектов) выборки.

Затем для каждого числа экспертов $E \in \{2, 4, 8, 16, 32, 64, 128\}$ создавался **ученик** — слой МоЕ той же архитектуры, но с E экспертами, и обучался предсказывать выходы учителя с функцией потерь $\frac{1}{2} \|\mathbf{z}_{\text{ученика}} - \mathbf{z}_{\text{учителя}}\|_2^2$, для которой $M_{\mathbf{A}} = 1$. Обучение велось 20 эпох оптимизатором Adam с learning rate 10^{-3} ; все эксперты были активны ($K = E$).

После обучения для каждого значения E выбиралась фиксированная подвыборка из $m = 16$ тестовых объектов. На этой подвыборке вычислялись:

- спектральная норма $\|\mathbf{G}\|_2$ гаусс–ньютоновской компоненты с помощью степенного метода;
- значение оценки без множителя S_g ;
- значение оценки из теоремы 1.

Среднее значение $S_g = \sum_{e=1}^E g_e^2$ дополнительно вычислялось по всей тестовой выборке.

Для краткости обозначим через B_0 оценку без множителя S_g , а через B_{S_g} — оценку из теоремы 1:

$$B_0 = M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2),$$

$$B_{S_g} = M_{\mathbf{A}} M_{\mathbf{x}}^2 S_g (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

4.2 Эксперимент с полным ViT+MoE на MNIST

Чтобы проверить, сохраняется ли зависимость от S_g в более сложных условиях, был проведён дополнительный эксперимент на реальных данных. Использовалась архитектура ViT с одним трансформерным блоком, в котором FFN-часть заменена на слой MoE (softmax-гейтинг, $K=E$, $d=16$, $d_{\text{ff}}=64$). Модель обучалась на MNIST (5 эпох, Adam, $\text{lr } 10^{-3}$) при различном числе экспертов $E \in \{2, 4, 8, 16, 32\}$. Для каждого E измерялись спектральная норма $\|\mathbf{G}\|_2$ (только по параметрам MoE-слоя) и среднее значение S_g на тестовой выборке. Формальные условия теоремы здесь не выполняются (кросс-энтропия, наличие attention-блока), поэтому теоретические границы не вычислялись.

4.3 Результаты

На рис. 1 приведено сравнение эмпирической нормы $\|\mathbf{G}\|_2$ с двумя теоретическими границами. Левая панель показывает сами величины в логарифмическом масштабе, а правая — отношение эмпирической нормы к каждой из границ.




Рис. 1: Сравнение эмпирической нормы $\|\mathbf{G}\|_2$ с оценками B_0 и B_{S_g} .

Из рис. 1 видно, что оценка B_0 без множителя S_g практически не отражает зависимость от числа экспертов: при увеличении E эмпирическая норма $\|\mathbf{G}\|_2$ убывает, тогда как эта граница остаётся существенно более грубой. Напротив, оценка B_{S_g} убывает вместе с эмпирической нормой и лучше передаёт зависимость от числа экспертов. Более того, отношение $\|\mathbf{G}\|_2 / B_{S_g}$ выходит на почти постоянный уровень при больших E . Это указывает на то, что множитель S_g действительно выделяет основную зависимость гаусс—ньютоновской компоненты от числа экспертов.

Дополнительно на рис. 2 показана зависимость среднего значения $S_g = \sum_{e=1}^E g_e^2$ от E ; пунктиром показана зависимость $1/E$. В рассматриваемом эксперименте величина S_g практически совпадает с $1/E$, что соответствует почти равномерному softmax-гейтингу. Поэтому убывание границы B_{S_g} в этом эксперименте определяется главным образом множителем S_g , а не изменением остальных множителей оценки. Это ожидаемо: все эксперты имеют одинаковую архитектуру, все они активны, а синтетическая




Рис. 2: Среднее значение S_g при различном числе экспертов E

задача не содержит явного механизма, стимулирующего специализацию отдельных экспертов. Поэтому рост числа экспертов приводит к уменьшению S_g и, как следствие, к уменьшению границы B_{S_g} .

Результаты эксперимента с полным ViT+MoE на MNIST приведены на рис. 3.




Рис. 3: Поведение $\|\mathbf{G}\|_2$ и S_g в ViT+MoE на MNIST.

Видно, что S_g монотонно убывает с ростом E , приблизительно следуя закону $E^{-0.75}$. Норма $\|\mathbf{G}\|_2$ также убывает при $E \leq 32$, хотя и медленнее. Отношение $\|\mathbf{G}\|_2/S_g$ не является строго постоянным, но меняется значительно слабее, чем сами величины. Это указывает на то, что множитель S_g остаётся ключевым фактором, определяющим масштаб кривизны, даже когда прямое применение теоремы невозможно.

5 Заключение

В работе получена явная верхняя оценка спектральной нормы гаусс-ньютоновской компоненты матрицы Гессе для одного слоя смеси экспертов. Основные результаты:

1. Оценка выражается через нормы весов экспертов (M_1, M_2) , норму входного вектора M_x , матрицу кривизны функции потерь M_A и **сумму квадратов коэффициентов гейтинга S_g** .
2. За счёт учёта S_g оценка существенно точнее ранее известных, которые фактически заменяли

S_g на единицу. При $S_g \approx 1/E$ (равномерный гейтинг) новая граница убывает с ростом числа экспертов, что полностью соответствует экспериментальным данным.

3. Для разрежённого top- K варианта оценка сохраняется с заменой S_g на $\sum_{e \in \mathcal{T}} g_e^2$, и при $S_g \approx 1/K$ граница масштабируется как $1/K$.
4. Эксперименты в схеме «учитель–ученик» на синтетических данных согласуются с теоретической оценкой: граница с множителем S_g убывает вместе с эмпирической нормой $\|\mathbf{G}\|_2$, а отношение $\|\mathbf{G}\|_2/B_{S_g}$ выходит на плато.
5. Дополнительный анализ на полном ViT+MoE (MNIST) показывает, что S_g сохраняет роль основного масштабирующего фактора и в более сложных условиях, даже когда формальные предположения теоремы нарушены.

Полученные результаты создают основу для анализа стабилизации ландшафта функции потерь при масштабировании MoE-моделей (росте числа экспертов или числа активных экспертов) и могут быть использованы для получения оценок требуемого объёма выборки в духе работ [5, 6]. В качестве дальнейших направлений представляет интерес распространение оценок на многослойные архитектуры со вниманием, а также изучение поведения S_g в задачах, где эксперты приобретают выраженную специализацию.

Список литературы

- [1] Jacobs R. A., Jordan M. I., Nowlan S. J., Hinton G. E. Adaptive mixtures of local experts // Neural Computation. 1991. Vol. 3, No. 1. P. 79–87.
- [2] Shazeer N., Mirhoseini A., Maziarz K., Davis A., Le Q. V., Hinton G., Dean J. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer // ICLR. 2017.
- [3] Papayan V. Measurements of three-level hierarchical structure in the outliers in the spectrum of deepnet Hessians // ICML. 2019.
- [4] Fort S., Ganguli S. Emergent properties of the local geometry of neural loss landscapes // arXiv:1910.05929. 2019.
- [5] Kiselev N. S., Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics. 2024.
- [6] Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // 2024 Ivannikov ISPRAS Open Conference. 2024.
- [7] Fedus W., Zoph B., Shazeer N. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity // JMLR. 2022. Vol. 23, No. 120. P. 1–39.
- [8] Jiang A. Q., Sablayrolles A., Roux A., et al. Mixtral of Experts // arXiv:2401.04088. 2024.
- [9] DeepSeek-AI, Liu A., Feng B., et al. DeepSeek-V3 Technical Report // arXiv:2412.19437. 2025.