

Улучшение оценки нормы разности гессианов для модели смеси экспертов

Игнатъев Даниил и Никита Киселёв
ignatev.daniil@phystech.edu

Аннотация

Модель смеси экспертов (МоЕ) является эффективной архитектурой для масштабирования нейронных сетей, однако её локальные геометрические свойства, в частности структура матрицы Гессе, остаются малоизученными. В данной работе исследуется гаусс-ньютоновская компонента матрицы Гессе для модели МоЕ. Используя подход матрично-представимых сетей, разработанный ранее для полносвязных, сверточных и трансформерных архитектур, мы выводим явную верхнюю оценку спектральной нормы этой компоненты. Оценка выражается через нормы весов экспертов и гейтинга, нормы входных данных и архитектурные параметры (число экспертов, размерности слоев). Полученный результат позволяет анализировать влияние числа экспертов на кривизну поверхности функции потерь и может быть использован для изучения стабилизации ландшафта МоЕ при увеличении объема выборки. Экспериментальная валидация планируется на синтетических данных и задачах классификации.

Ключевые слова: смесь экспертов, матрица Гессе, гаусс-ньютоновское приближение, спектральная норма, матрично-представимые сети.

1 Введение

Модель смеси экспертов (Mixture of Experts, MoE) [1, 2, 7] широко применяется для построения больших нейронных сетей благодаря возможности разреженной активации экспертов, эффективного масштабирования и снижения вычислительных затрат при увеличении числа параметров. Однако теоретическое понимание свойств оптимизационной поверхности МоЕ, в частности её кривизны, остаётся ограниченным. Между тем, анализ матрицы Гессе функции потерь играет ключевую роль в изучении сходимости обучения и стабилизации ландшафта при увеличении объема данных [3, 4].

В работах [5, 6] был развит подход к анализу спектральных свойств матрицы Гессе для матрично-представимых нейронных сетей, основанный на разложении Гаусса–Ньютона $\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$ и оценке нормы гаусс-ньютоновской компоненты $\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$. Для полносвязных, сверточных и трансформерных сетей были получены явные верхние оценки $\|\mathbf{G}(\mathbf{w})\|_2$, выраженные через нормы весов, активаций и архитектурные параметры. Данная методология может быть распространена на модель МоЕ, если представить её в виде матрично-представимой сети.

Особый интерес представляют разреженные варианты маршрутизации, при которых для каждого входа активируется только подмножество экспертов. Именно такие механизмы используются в современных sparse MoE-архитектурах, например в Mixtral [8]. Поэтому наряду с полным softmax-гейтингом важно рассмотреть и его разреженные модификации, возникающие после top- K -отбора экспертов.

Целью настоящей работы является получение явной верхней оценки спектральной нормы гаусс—ньютоновской компоненты матрицы Гессе для одного слоя смеси экспертов с softmax-гейтингом и связанных с ним разреженных вариантов маршрутизации. Такая оценка позволит в дальнейшем использовать критерии сходимости ландшафта [5] для МоЕ-архитектур и анализировать влияние числа экспертов и схемы маршрутизации на локальную геометрию поверхности функции потерь.

2 Постановка задачи

2.1 Модель смеси экспертов

Рассмотрим задачу обучения с учителем, где объект представлен парой $(\mathbf{x}, y)$, $\mathbf{x} \in \mathbb{R}^{d_{\text{in}}}$, $y \in \mathbb{Y}$. Определим **один слой смеси экспертов (МоЕ)**, который в архитектуре трансформера обычно заменяет блок Feed-Forward Network (FFN). Слой состоит из E экспертов и обучаемого гейтинга (роутера). Каждый эксперт представляет собой двухслойную полносвязную сеть с активацией ReLU:

$$\text{FFN}_e(\mathbf{x}) = \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)}\mathbf{x} + \mathbf{b}_e^{(1)}) + \mathbf{b}_e^{(2)}, \quad e = 1, \dots, E,$$

где $\mathbf{W}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}} \times d_{\text{in}}}$, $\mathbf{b}_e^{(1)} \in \mathbb{R}^{d_{\text{ff}}}$, $\mathbf{W}_e^{(2)} \in \mathbb{R}^{d_{\text{out}} \times d_{\text{ff}}}$, $\mathbf{b}_e^{(2)} \in \mathbb{R}^{d_{\text{out}}}$. Для простоты будем полагать $d_{\text{out}} = d_{\text{in}} = d$, как в стандартных трансформерных блоках.

Параметры всех экспертов обозначим $\mathbf{w}_{\text{exp}} = (\mathbf{w}_1, \dots, \mathbf{w}_E)$, где $\mathbf{w}_e$ объединяет все веса и смещения e -го эксперта.

Гейтинг (роутер). Рассмотрим три варианта маршрутизации, различающихся гладкостью и степенью разреженности.

1. *Полный softmax по всем экспертам.* Классический роутер имеет вид

$$g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^\top \mathbf{x} + b_e)}{\sum_{j=1}^E \exp(\mathbf{a}_j^\top \mathbf{x} + b_j)}, \quad e = 1, \dots, E,$$

где $\mathbf{a}_e \in \mathbb{R}^d$, $b_e \in \mathbb{R}$. Совокупность параметров роутера обозначим через

$$\mathbf{w}_g = (\mathbf{a}_1, \dots, \mathbf{a}_E, b_1, \dots, b_E) \in \mathbb{R}^{E(d+1)}.$$

2. *Топ- K по логитам с softmax-перенормировкой на активном множестве.* Для каждого входа $\mathbf{x}$ вычисляются логиты

$$s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x} + b_e, \quad e = 1, \dots, E,$$

и множество активных экспертов $\mathcal{T}(\mathbf{x})$ состоит из K индексов, соответствующих наибольшим значениям $s_e(\mathbf{x})$. Тогда коэффициенты гейтинга задаются формулой

$$\tilde{g}_e(\mathbf{x}) = \begin{cases} \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}, & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases}$$

3. *Топ- K после полного softmax без дополнительной перенормировки.* В этом случае сначала вы-

числяются коэффициенты $g_e(\mathbf{x})$ полного softmax, после чего сохраняются только K наибольших коэффициентов:

$$\hat{g}_e(\mathbf{x}) = \begin{cases} g_e(\mathbf{x}), & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases}$$

Первые два варианта совпадают после перенормировки на активном множестве, поскольку softmax сохраняет порядок координат. Третий вариант отличается тем, что сумма активных коэффициентов, вообще говоря, меньше единицы.

Архитектура без общего эксперта. Выход МоЕ-слоя формируется как взвешенная сумма выходов экспертов:

$$\mathbf{z} = \sum_{e=1}^E \gamma_e(\mathbf{x}) \text{FFN}_e(\mathbf{x}),$$

где γ_e обозначает один из рассмотренных выше вариантов гейтинга. Полный вектор параметров модели имеет вид

$$\mathbf{w} = (\mathbf{w}_{\text{exp}}, \mathbf{w}_g).$$

В теоретической части ниже для краткости все смещения в экспертных и роутерных блоках опускаются. Это упрощает записи, но не меняет структуры доказательств и порядка получаемых оценок.

2.2 Функция потерь и матрица Гессе

Пусть задана дважды дифференцируемая функция потерь $\ell(\mathbf{z}, y)$ (например, квадратичная потеря или кросс-энтропия). Для одного объекта $(\mathbf{x}, y)$ определим эмпирическую функцию потерь как $\ell(\mathbf{z}(\mathbf{w}), y)$, где $\mathbf{z}(\mathbf{w})$ — выход МоЕ-слоя. Матрица Гессе этой функции по параметрам $\mathbf{w}$ допускает разложение Гаусса–Ньютона [6]:

$$\mathbf{H}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}) + \mathbf{R}(\mathbf{w}),$$

где $\mathbf{J}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}} \in \mathbb{R}^{d \times N}$ — якобиан выхода по параметрам, $\mathbf{A}(\mathbf{w}) = \nabla_{\mathbf{z}}^2 \ell(\mathbf{z}, y) \in \mathbb{R}^{d \times d}$ — матрица кривизны функции потерь по выходу, $\mathbf{R}(\mathbf{w})$ — остаточная компонента, связанная со вторыми производными выхода по параметрам.

Как показано в [5, 6], для анализа локальных свойств ландшафта часто достаточно оценить спектральную норму гаусс–ньютоновской компоненты

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w}),$$

поскольку остаточная компонента $\mathbf{R}(\mathbf{w})$ в окрестности минимума мала или ограничена по норме.

3 Теоретическая часть

3.1 Матрично-представимое представление МоЕ и факторизация гаусс–ньютоновской компоненты

Для получения явной оценки нормы гаусс–ньютоновской компоненты удобно использовать представление МоЕ-слоя как матрично-представимой нейронной сети.

Определение 3.1. Нейронная сеть называется *матрично-представимой*, если ее выход $\mathbf{z} = f_{\mathbf{w}}(\mathbf{x})$ для входа $\mathbf{x}$ может быть записан в виде

$$\mathbf{x}^{(1)} = \mathbf{x}, \quad \mathbf{z}^{(p)} = T_{\mathbf{w}^{(p)}}^{(p)}(\mathbf{x}^{(p)}), \quad \mathbf{x}^{(p+1)} = \sigma^{(p)}(\mathbf{z}^{(p)}), \quad p = 1, \dots, L-1,$$

$$\mathbf{z} = \mathbf{z}^{(L)} = T_{\mathbf{w}^{(L)}}^{(L)}(\mathbf{x}^{(L)}),$$

где $\mathbf{w} = \text{col}(\mathbf{w}^{(1)}, \dots, \mathbf{w}^{(L)})$, а каждый оператор $T_{\mathbf{w}^{(p)}}^{(p)} : \mathbb{R}^{n_{p-1}} \rightarrow \mathbb{R}^{n_p}$ линеен по входу $\mathbf{x}^{(p)}$.

Для каждого слоя введем матрицу распространения возмущения преактивации к выходу сети

$$\mathbf{S}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{z}^{(p)}}$$

и параметрический якобиан слоя

$$\mathbf{P}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}^{(p)}}{\partial \mathbf{w}^{(p)}}.$$

Лемма 3.2. Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью. Тогда якобиан выхода сети по параметрам p -го слоя факторизуется в виде

$$\mathbf{J}^{(p)}(\mathbf{w}) = \frac{\partial \mathbf{z}}{\partial \mathbf{w}^{(p)}} = \mathbf{S}^{(p)}(\mathbf{w}) \mathbf{P}^{(p)}(\mathbf{w}).$$

Следовательно,

$$\mathbf{J}(\mathbf{w}) = [\mathbf{S}^{(1)}(\mathbf{w}) \mathbf{P}^{(1)}(\mathbf{w}), \dots, \mathbf{S}^{(L)}(\mathbf{w}) \mathbf{P}^{(L)}(\mathbf{w})].$$

Доказательство. Утверждение следует из правила дифференцирования сложной функции и блочной структуры вектора параметров $\mathbf{w}$. $\square$

Лемма 3.3. Пусть $f_{\mathbf{w}}$ является матрично-представимой нейронной сетью, а

$$\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$$

есть гаусс—ньютоновская компонента матрицы Гессе. Тогда $\mathbf{G}(\mathbf{w})$ имеет блочную структуру

$$\mathbf{G}(\mathbf{w}) = [\mathbf{G}^{(p,q)}(\mathbf{w})]_{p,q=1}^L, \quad \mathbf{G}^{(p,q)}(\mathbf{w}) = \mathbf{P}^{(p)}(\mathbf{w})^\top \mathbf{S}^{(p)}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{S}^{(q)}(\mathbf{w}) \mathbf{P}^{(q)}(\mathbf{w}).$$

Доказательство. Подстановка факторизации из леммы 3.2 в определение $\mathbf{G}(\mathbf{w})$ дает требуемое блочное представление. $\square$

3.2 Оценка гаусс—ньютоновской компоненты для МоЕ с softmax-гейтингом

Рассмотрим один слой смеси экспертов без смещений:

$$\mathbf{z} = \sum_{e=1}^E g_e(\mathbf{x}) \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}), \quad (1)$$

где коэффициенты гейтинга определяются формулой

$$g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^\top \mathbf{x})}{\sum_{j=1}^E \exp(\mathbf{a}_j^\top \mathbf{x})}, \quad e = 1, \dots, E. \quad (2)$$

Ниже смещения в экспертных и роутерных блоках опускаются для краткости. Их учет не меняет структуру доказательств и порядок получаемых оценок.

Введем обозначения

$$\mathbf{u}_e = \mathbf{W}_e^{(1)} \mathbf{x}, \quad \mathbf{r}_e = \text{ReLU}(\mathbf{u}_e), \quad \mathbf{s} = \mathbf{U} \mathbf{x}, \quad \mathbf{U} = \begin{bmatrix} \mathbf{a}_1^\top \\ \vdots \\ \mathbf{a}_E^\top \end{bmatrix} \in \mathbb{R}^{E \times d}.$$

Лемма 3.4. *Модель (1)–(2) является матрично-представимой нейронной сетью глубины $L = 2$.*

Доказательство. Положим

$$\mathbf{z}^{(1)} = \begin{bmatrix} \mathbf{W}_1^{(1)} \mathbf{x} \\ \vdots \\ \mathbf{W}_E^{(1)} \mathbf{x} \\ \mathbf{U} \mathbf{x} \end{bmatrix} \in \mathbb{R}^{Ed_{\text{ff}} + E}$$

и определим нелинейность

$$\sigma_{\text{MoE}} \left(\begin{bmatrix} \mathbf{u}_1 \\ \vdots \\ \mathbf{u}_E \\ \mathbf{s} \end{bmatrix} \right) = \begin{bmatrix} g_1(\mathbf{s}) \text{ReLU}(\mathbf{u}_1) \\ \vdots \\ g_E(\mathbf{s}) \text{ReLU}(\mathbf{u}_E) \\ \mathbf{s} \end{bmatrix} = \mathbf{x}^{(2)},$$

где $g_e(\mathbf{s}) = \exp(s_e) / \sum_{j=1}^E \exp(s_j)$. Тогда

$$\mathbf{z} = \begin{bmatrix} \mathbf{W}_1^{(2)} & \dots & \mathbf{W}_E^{(2)} & \mathbf{0}_{d \times E} \end{bmatrix} \mathbf{x}^{(2)},$$

то есть модель является матрично-представимой сетью глубины $L = 2$. □

В силу леммы 3.4

$$\mathbf{J}(\mathbf{w}) = [\mathbf{J}^{(1)}(\mathbf{w}), \mathbf{J}^{(2)}(\mathbf{w})] = [\mathbf{S}^{(1)}(\mathbf{w}) \mathbf{P}^{(1)}(\mathbf{w}), \mathbf{S}^{(2)}(\mathbf{w}) \mathbf{P}^{(2)}(\mathbf{w})].$$

Теорема 3.5. *Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1)–(2). Предположим, что существуют положительные константы $M_{\mathbf{x}}, M_{\mathbf{A}}, M_1, M_2$ такие, что*

$$\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}, \quad \|\mathbf{A}(\mathbf{w})\|_2 \leq M_{\mathbf{A}}, \quad \|\mathbf{W}_e^{(1)}\|_2 \leq M_1, \quad \|\mathbf{W}_e^{(2)}\|_2 \leq M_2, \quad e = 1, \dots, E. \quad (3)$$

Тогда для гаусс–ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (4)$$

Доказательство. **Оценка $\mathbf{P}^{(1)}(\mathbf{w})$.** Пусть

$$\mathbf{w}^{(1)} = \text{col}(\mathbf{W}_1^{(1)}, \dots, \mathbf{W}_E^{(1)}, \mathbf{a}_1, \dots, \mathbf{a}_E).$$

Тогда для произвольного приращения $\Delta \mathbf{w}^{(1)}$ имеем

$$\mathbf{P}^{(1)}(\mathbf{w})\Delta \mathbf{w}^{(1)} = \begin{bmatrix} \Delta \mathbf{W}_1^{(1)} \mathbf{x} \\ \vdots \\ \Delta \mathbf{W}_E^{(1)} \mathbf{x} \\ \Delta \mathbf{U} \mathbf{x} \end{bmatrix}, \quad \Delta \mathbf{U} = \begin{bmatrix} \Delta \mathbf{a}_1^\top \\ \vdots \\ \Delta \mathbf{a}_E^\top \end{bmatrix}.$$

Следовательно,

$$\begin{aligned} \|\mathbf{P}^{(1)}(\mathbf{w})\Delta \mathbf{w}^{(1)}\|_2^2 &= \sum_{e=1}^E \|\Delta \mathbf{W}_e^{(1)} \mathbf{x}\|_2^2 + \|\Delta \mathbf{U} \mathbf{x}\|_2^2 \\ &\leq \|\mathbf{x}\|_2^2 \left(\sum_{e=1}^E \|\Delta \mathbf{W}_e^{(1)}\|_F^2 + \|\Delta \mathbf{U}\|_F^2 \right) = \|\mathbf{x}\|_2^2 \|\Delta \mathbf{w}^{(1)}\|_2^2. \end{aligned}$$

Отсюда

$$\|\mathbf{P}^{(1)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}}.$$

Оценка $\mathbf{P}^{(2)}(\mathbf{w})$. Поскольку

$$\mathbf{x}^{(2)} = \begin{bmatrix} g_1(\mathbf{s}) \mathbf{r}_1 \\ \vdots \\ g_E(\mathbf{s}) \mathbf{r}_E \\ \mathbf{s} \end{bmatrix},$$

а последние E координат умножаются на нулевой блок, имеем

$$\mathbf{P}^{(2)}(\mathbf{w})\Delta \mathbf{w}^{(2)} = \sum_{e=1}^E \Delta \mathbf{W}_e^{(2)} (g_e(\mathbf{s}) \mathbf{r}_e).$$

Поэтому

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e=1}^E g_e(\mathbf{s})^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2}.$$

Так как

$$\|\mathbf{r}_e\|_2 \leq \|\mathbf{u}_e\|_2 \leq \|\mathbf{W}_e^{(1)}\|_2 \|\mathbf{x}\|_2 \leq M_1 M_{\mathbf{x}},$$

получаем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 \leq \left(\sum_{e=1}^E g_e(\mathbf{s})^2 (M_1 M_{\mathbf{x}})^2 \right)^{1/2} \leq M_1 M_{\mathbf{x}},$$

поскольку $\sum_{e=1}^E g_e(\mathbf{s})^2 \leq 1$.

Оценка $\mathbf{S}^{(2)}(\mathbf{w})$. Так как $\mathbf{z} = \mathbf{z}^{(2)}$, имеем

$$\mathbf{S}^{(2)}(\mathbf{w}) = \mathbf{I}_d, \quad \|\mathbf{S}^{(2)}(\mathbf{w})\|_2 = 1.$$

Оценка $\mathbf{S}^{(1)}(\mathbf{w})$. Рассмотрим произвольное возмущение

$$\Delta \mathbf{z}^{(1)} = \begin{bmatrix} \Delta \mathbf{u}_1 \\ \vdots \\ \Delta \mathbf{u}_E \\ \Delta \mathbf{s} \end{bmatrix}, \quad \Delta \mathbf{z} = \Delta \mathbf{z}_{\mathbf{u}} + \Delta \mathbf{z}_{\mathbf{s}}.$$

Для первого слагаемого положим $\mathbf{D}_e = \text{diag}(\text{ReLU}'(\mathbf{u}_e))$. Тогда почти всюду $\|\mathbf{D}_e\|_2 \leq 1$, и

$$\Delta \mathbf{z}_{\mathbf{u}} = \sum_{e=1}^E g_e(\mathbf{s}) \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e.$$

Следовательно,

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{u}}\|_2 &\leq \sum_{e=1}^E g_e(\mathbf{s}) \|\mathbf{W}_e^{(2)}\|_2 \|\mathbf{D}_e\|_2 \|\Delta \mathbf{u}_e\|_2 \\ &\leq M_2 \sum_{e=1}^E g_e(\mathbf{s}) \|\Delta \mathbf{u}_e\|_2 \leq M_2 \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}. \end{aligned}$$

Для второго слагаемого обозначим $\mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{r}_e$. Тогда

$$\|\mathbf{y}_e\|_2 \leq \|\mathbf{W}_e^{(2)}\|_2 \|\mathbf{r}_e\|_2 \leq M_1 M_2 M_{\mathbf{x}}.$$

Кроме того,

$$\Delta g_e = g_e(\mathbf{s}) \left(\Delta s_e - \sum_{j=1}^E g_j(\mathbf{s}) \Delta s_j \right).$$

Обозначим $\overline{\Delta s} = \sum_{j=1}^E g_j(\mathbf{s}) \Delta s_j$. Тогда

$$\Delta \mathbf{z}_{\mathbf{s}} = \sum_{e=1}^E g_e(\mathbf{s}) (\Delta s_e - \overline{\Delta s}) \mathbf{y}_e,$$

и потому

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{s}}\|_2 &\leq \sum_{e=1}^E g_e(\mathbf{s}) |\Delta s_e - \overline{\Delta s}| \|\mathbf{y}_e\|_2 \\ &\leq M_1 M_2 M_{\mathbf{x}} \sum_{e=1}^E g_e(\mathbf{s}) |\Delta s_e - \overline{\Delta s}| \\ &\leq M_1 M_2 M_{\mathbf{x}} \left(\sum_{e=1}^E g_e(\mathbf{s}) (\Delta s_e - \overline{\Delta s})^2 \right)^{1/2} \leq M_1 M_2 M_{\mathbf{x}} \|\Delta \mathbf{s}\|_2. \end{aligned}$$

Итак,

$$\|\Delta \mathbf{z}\|_2 \leq M_2 \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} + M_1 M_2 M_{\mathbf{x}} \|\Delta \mathbf{s}\|_2.$$

По неравенству Коши–Буняковского отсюда следует

$$\|\Delta \mathbf{z}\|_2 \leq M_2 \sqrt{1 + M_1^2 M_{\mathbf{x}}^2} \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 + \|\Delta \mathbf{s}\|_2^2 \right)^{1/2},$$

то есть

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{1 + M_1^2 M_{\mathbf{x}}^2}.$$

Завершение доказательства. Полученные оценки дают

$$\|\mathbf{J}^{(1)}(\mathbf{w})\|_2 \leq M_2 M_{\mathbf{x}} \sqrt{1 + M_1^2 M_{\mathbf{x}}^2}, \quad \|\mathbf{J}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}}.$$

Следовательно,

$$\begin{aligned} \|\mathbf{J}(\mathbf{w})\|_2^2 &= \|\mathbf{J}(\mathbf{w})\mathbf{J}(\mathbf{w})^\top\|_2 \\ &\leq \|\mathbf{J}^{(1)}(\mathbf{w})\|_2^2 + \|\mathbf{J}^{(2)}(\mathbf{w})\|_2^2 \\ &\leq M_2^2 M_{\mathbf{x}}^2 (1 + M_1^2 M_{\mathbf{x}}^2) + M_1^2 M_{\mathbf{x}}^2 \\ &= M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2). \end{aligned}$$

Так как $\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2^2$, из (3) получаем (4). $\square$

Замечание 3.6. Если оценивать матрицу распространения первого слоя грубо через норму конкатенированного выходного оператора, то

$$\left\| \begin{bmatrix} \mathbf{W}_1^{(2)} & \dots & \mathbf{W}_E^{(2)} \end{bmatrix} \right\|_2 \leq \sqrt{E} M_2,$$

и потому

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + E M_2^2 + E M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Таким образом, аккуратный анализ softmax-структуры устраняет множитель E из улучшенной оценки, тогда как прямое огрубление через норму конкатенированного оператора его сохраняет.

3.3 Следствия для разреженных вариантов softmax-гейтинга

Ниже рассматриваются разреженные варианты маршрутизации, возникающие из softmax-гейтинга. При фиксированном входе $\mathbf{x}$ активное множество определяется параметрами роутера; условие строгого разделения логитов обеспечивает его локальную постоянность в окрестности рассматриваемого параметра $\mathbf{w}$.

Следствие 3.7. Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1), в котором множество активных экспертов состоит из K индексов, соответствующих наибольшим значениям логитов $s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x}$, а коэффициенты гейтинга задаются формулой

$$\tilde{g}_e(\mathbf{x}) = \begin{cases} \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}, & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases} \quad (5)$$

Предположим, что выполнены условия (3). Пусть, кроме того, в рассматриваемой точке выполнено

условие строгого разделения

$$s_{(K)}(\mathbf{x}) > s_{(K+1)}(\mathbf{x}), \quad (6)$$

где $s_{(1)}(\mathbf{x}) \geq \dots \geq s_{(E)}(\mathbf{x})$ — логиты роутера, упорядоченные по невозрастанию. Тогда в некоторой окрестности рассматриваемого параметра $\mathbf{w}$ активное множество $\mathcal{T}(\mathbf{x})$ постоянно, и для гаусс-ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (7)$$

Доказательство. Условие (6) обеспечивает локальную постоянность активного множества. Зафиксируем его и обозначим через $\mathcal{T}$.

На этой окрестности модель совпадает с гладкой МоЕ-архитектурой, где softmax вычисляется только по индексам из $\mathcal{T}$. Поэтому доказательство повторяет доказательство теоремы 3.5 после замены сумм по $e = 1, \dots, E$ на суммы по $e \in \mathcal{T}$ и коэффициентов g_e на $\tilde{g}_e$.

При этом оценка для $\mathbf{P}^{(1)}(\mathbf{w})$ не меняется, а для $\mathbf{P}^{(2)}(\mathbf{w})$ имеем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e \in \mathcal{T}} \tilde{g}_e(\mathbf{s})^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2} \leq M_1 M_{\mathbf{x}},$$

поскольку $\sum_{e \in \mathcal{T}} \tilde{g}_e(\mathbf{s})^2 \leq 1$.

Аналогично,

$$\|\Delta \mathbf{z}_{\mathbf{u}}\|_2 \leq M_2 \left(\sum_{e \in \mathcal{T}} \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} \leq M_2 \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2},$$

а для возмущения коэффициентов гейтинга сохраняется оценка

$$\|\Delta \mathbf{z}_{\mathbf{s}}\|_2 \leq M_1 M_2 M_{\mathbf{x}} \|\Delta \mathbf{s}\|_2.$$

Следовательно,

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{1 + M_1^2 M_{\mathbf{x}}^2}.$$

Тем самым оценки для $\|\mathbf{J}^{(1)}(\mathbf{w})\|_2$, $\|\mathbf{J}^{(2)}(\mathbf{w})\|_2$ и $\|\mathbf{J}(\mathbf{w})\|_2^2$ совпадают с оценками из доказательства теоремы 3.5, откуда и следует (7). $\square$

Замечание 3.8. Следствие 3.7 охватывает маршрутирование, в котором сначала выбираются top- K логитов роутера, а затем softmax вычисляется только на активном множестве. Такой механизм используется например в Mixtral [8].

Замечание 3.9. Если сначала вычисляется полный softmax по всем экспертам, затем сохраняются top- K коэффициентов и выполняется перенормировка на активном множестве, то получающиеся веса совпадают с (5). Действительно, softmax сохраняет порядок координат, а для $e \in \mathcal{T}(\mathbf{x})$ имеем

$$\frac{g_e(\mathbf{x})}{\sum_{j \in \mathcal{T}(\mathbf{x})} g_j(\mathbf{x})} = \frac{\exp(s_e(\mathbf{x}))}{\sum_{j \in \mathcal{T}(\mathbf{x})} \exp(s_j(\mathbf{x}))}.$$

Следовательно, следствие 3.7 покрывает оба эквивалентных варианта: «top- K по логитам, затем softmax на активном множестве» и «полный softmax, затем top- K и перенормировка».

Замечание 3.10. Если в случае $\text{top-}K$ -гейтинга оценивать матрицу распространения первого слоя грубо через норму конкатенированного выходного оператора по активным экспертам, то

$$\left\| \left[\mathbf{W}_e^{(2)} \right]_{e \in \mathcal{T}} \right\|_2 \leq \sqrt{K} M_2.$$

Тогда получаем более слабую, но явную по числу активных экспертов оценку

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + K M_2^2 + K M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Таким образом, аккуратный анализ softmax-структуры на фиксированном активном множестве устраняет явную зависимость от K из улучшенной оценки, тогда как прямое огрубление через норму конкатенированного оператора ее сохраняет.

Следствие 3.11. Пусть $f_{\mathbf{w}}$ является одним слоем смеси экспертов вида (1), в котором сначала вычисляются softmax-коэффициенты (2), а затем применяется $\text{top-}K$ -отбор без дополнительной перенормировки:

$$\hat{g}_e(\mathbf{x}) = \begin{cases} g_e(\mathbf{x}), & e \in \mathcal{T}(\mathbf{x}), \\ 0, & e \notin \mathcal{T}(\mathbf{x}). \end{cases} \quad (8)$$

Здесь $\mathcal{T}(\mathbf{x})$ есть множество K индексов, соответствующих наибольшим значениям логитов $s_e(\mathbf{x}) = \mathbf{a}_e^\top \mathbf{x}$. Предположим, что выполнены условия (3). Пусть, кроме того, выполнено условие строгого разделения (6). Тогда в некоторой окрестности рассматриваемого параметра $\mathbf{w}$ активное множество $\mathcal{T}(\mathbf{x})$ постоянно, и для гаусс–ньютоновской компоненты выполняется оценка

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2). \quad (9)$$

Доказательство. Условие (6) обеспечивает локальную постоянность активного множества. Зафиксируем его и обозначим через $\mathcal{T}$.

На этой окрестности выход модели имеет вид

$$\mathbf{z} = \sum_{e=1}^E \hat{g}_e(\mathbf{x}) \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}) = \sum_{e \in \mathcal{T}} g_e(\mathbf{x}) \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x}).$$

Оценка для $\mathbf{P}^{(1)}(\mathbf{w})$ остается прежней:

$$\|\mathbf{P}^{(1)}(\mathbf{w})\|_2 \leq M_{\mathbf{x}}.$$

Для $\mathbf{P}^{(2)}(\mathbf{w})$ имеем

$$\|\mathbf{P}^{(2)}(\mathbf{w})\|_2 = \left(\sum_{e \in \mathcal{T}} g_e(\mathbf{s})^2 \|\mathbf{r}_e\|_2^2 \right)^{1/2} \leq M_1 M_{\mathbf{x}},$$

поскольку $\sum_{e \in \mathcal{T}} g_e(\mathbf{s})^2 \leq \sum_{e=1}^E g_e(\mathbf{s})^2 \leq 1$. Кроме того,

$$\|\mathbf{S}^{(2)}(\mathbf{w})\|_2 = 1.$$

Для оценки $\mathbf{S}^{(1)}(\mathbf{w})$ рассмотрим возмущение

$$\Delta \mathbf{z}^{(1)} = \begin{bmatrix} \Delta \mathbf{u}_1 \\ \vdots \\ \Delta \mathbf{u}_E \\ \Delta \mathbf{s} \end{bmatrix}, \quad \Delta \mathbf{z} = \Delta \mathbf{z}_{\mathbf{u}} + \Delta \mathbf{z}_{\mathbf{s}}.$$

Тогда

$$\Delta \mathbf{z}_{\mathbf{u}} = \sum_{e \in \mathcal{T}} g_e(\mathbf{s}) \mathbf{W}_e^{(2)} \mathbf{D}_e \Delta \mathbf{u}_e, \quad \mathbf{D}_e = \text{diag}(\text{ReLU}'(\mathbf{u}_e)), \quad \|\mathbf{D}_e\|_2 \leq 1,$$

и потому

$$\|\Delta \mathbf{z}_{\mathbf{u}}\|_2 \leq M_2 \left(\sum_{e \in \mathcal{T}} \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} \leq M_2 \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2}.$$

Далее, если обозначить $\mathbf{y}_e = \mathbf{W}_e^{(2)} \mathbf{r}_e$, то $\|\mathbf{y}_e\|_2 \leq M_1 M_2 M_{\mathbf{x}}$, а из (8) следует, что для $e \in \mathcal{T}$

$$\Delta \hat{g}_e = \Delta g_e = g_e(\mathbf{s}) \left(\Delta s_e - \sum_{j=1}^E g_j(\mathbf{s}) \Delta s_j \right).$$

Обозначив $\overline{\Delta s} = \sum_{j=1}^E g_j(\mathbf{s}) \Delta s_j$, получаем

$$\Delta \mathbf{z}_{\mathbf{s}} = \sum_{e \in \mathcal{T}} g_e(\mathbf{s}) (\Delta s_e - \overline{\Delta s}) \mathbf{y}_e,$$

откуда

$$\begin{aligned} \|\Delta \mathbf{z}_{\mathbf{s}}\|_2 &\leq \sum_{e \in \mathcal{T}} g_e(\mathbf{s}) |\Delta s_e - \overline{\Delta s}| \|\mathbf{y}_e\|_2 \\ &\leq M_1 M_2 M_{\mathbf{x}} \sum_{e \in \mathcal{T}} g_e(\mathbf{s}) |\Delta s_e - \overline{\Delta s}| \\ &\leq M_1 M_2 M_{\mathbf{x}} \left(\sum_{e=1}^E g_e(\mathbf{s}) (\Delta s_e - \overline{\Delta s})^2 \right)^{1/2} \leq M_1 M_2 M_{\mathbf{x}} \|\Delta \mathbf{s}\|_2. \end{aligned}$$

Следовательно,

$$\|\Delta \mathbf{z}\|_2 \leq M_2 \left(\sum_{e=1}^E \|\Delta \mathbf{u}_e\|_2^2 \right)^{1/2} + M_1 M_2 M_{\mathbf{x}} \|\Delta \mathbf{s}\|_2,$$

а значит,

$$\|\mathbf{S}^{(1)}(\mathbf{w})\|_2 \leq M_2 \sqrt{1 + M_1^2 M_{\mathbf{x}}^2}.$$

Тем самым

$$\|\mathbf{J}^{(1)}(\mathbf{w})\|_2 \leq M_2 M_{\mathbf{x}} \sqrt{1 + M_1^2 M_{\mathbf{x}}^2}, \quad \|\mathbf{J}^{(2)}(\mathbf{w})\|_2 \leq M_1 M_{\mathbf{x}},$$

и потому

$$\|\mathbf{J}(\mathbf{w})\|_2^2 \leq M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Используя неравенство $\|\mathbf{G}(\mathbf{w})\|_2 \leq \|\mathbf{A}(\mathbf{w})\|_2 \|\mathbf{J}(\mathbf{w})\|_2$, получаем (9). □

Список литературы

- [1] Jacobs R. A., Jordan M. I., Nowlan S. J., Hinton G. E. Adaptive mixtures of local experts // Neural Computation. 1991. Vol. 3, No. 1. P. 79–87.
- [2] Shazeer N., Mirhoseini A., Maziarz K., Davis A., Le Q. V., Hinton G., Dean J. Outrageously large neural networks: The sparsely-gated mixture-of-experts layer // ICLR. 2017.
- [3] Papayan V. Measurements of three-level hierarchical structure in the outliers in the spectrum of deepnet Hessians // ICML. 2019.
- [4] Fort S., Ganguli S. Emergent properties of the local geometry of neural loss landscapes // arXiv:1910.05929. 2019.
- [5] Kiselev N. S., Grabovoy A. V. Unraveling the Hessian: A Key to Smooth Convergence in Loss Function Landscapes // Doklady Mathematics. 2024.
- [6] Meshkov V., Kiselev N., Grabovoy A. ConvNets Landscape Convergence: Hessian-Based Analysis of Matricized Networks // 2024 Ivannikov ISPRAS Open Conference. 2024.
- [7] Fedus W., Zoph B., Shazeer N. Switch Transformers: Scaling to Trillion Parameter Models with Simple and Efficient Sparsity // JMLR. 2022. Vol. 23, No. 120. P. 1–39.
- [8] Jiang A. Q., Sablayrolles A., Roux A., et al. Mixtral of Experts // arXiv:2401.04088. 2024.
- [9] DeepSeek-AI, Liu A., Feng B., et al. DeepSeek-V3 Technical Report // arXiv:2412.19437. 2025.