

Улучшение оценки нормы разности гессианов для модели смеси экспертов

Даниил Игнатьев

Консультант: Никита Киселёв, к.ф.-м.н.

Эксперт: Андрей Грабовой, к.ф.-м.н.

Курс: Моя первая научная статья
МФТИ, кафедра интеллектуальных систем

23 апреля 2026 г.

Цель и мотивация

Проблема

Локальная геометрия функции потерь для смеси экспертов (МоЕ) изучена слабо. Анализ гессиана необходим для понимания сходимости и требуемого объёма данных.

Цель

Получить явную верхнюю оценку спектральной нормы гаусс-ньютоновской компоненты $\|\mathbf{G}(\mathbf{w})\|_2$ для слоя МоЕ, выраженную через:

- ▶ нормы весов экспертов и гейтинга,
- ▶ норму входных данных,
- ▶ архитектурные параметры (число экспертов, размерности).

Зачем?

Оценка позволит анализировать стабилизацию ландшафта при масштабировании модели (увеличении числа экспертов E или числа активных экспертов K).



Основная идея

Для матрично-представимых сетей гессиан функции потерь раскладывается на две компоненты: $\mathbf{H}(\mathbf{w}) = \mathbf{G}(\mathbf{w}) + \mathbf{R}(\mathbf{w})$, $\mathbf{G}(\mathbf{w}) = \mathbf{J}(\mathbf{w})^\top \mathbf{A}(\mathbf{w}) \mathbf{J}(\mathbf{w})$.

Блочная факторизация якобиана:

$$\mathbf{J}^{(p)} = \mathbf{S}^{(p)} \mathbf{P}^{(p)}, \quad \mathbf{G}^{(p,q)} = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A} \mathbf{S}^{(q)} \mathbf{P}^{(q)}.$$

Цель: верхняя оценка $\|\mathbf{G}\|_2$ через нормы весов и архитектурные параметры.



Постановка задачи

Гипотеза

Спектральную норму $\|\mathbf{G}(\mathbf{w})\|_2$ для MoE-слоя можно ограничить сверху выражением, которое не содержит явного множителя E (полного числа экспертов) и не деградирует при переходе к разреженной top- K маршрутизации.

Модель

Один слой MoE: $\mathbf{z} = \sum_{e=1}^E \gamma_e(\mathbf{x}) \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x})$,

γ_e — softmax (или top- K с softmax на активном множестве).

Функция потерь $\ell(\mathbf{z}, y)$ дважды дифференцируема. Гессиан $\mathbf{H} = \mathbf{G} + \mathbf{R}$, $\mathbf{G} = \mathbf{J}^\top \mathbf{A} \mathbf{J}$, $\mathbf{A} = \nabla_{\mathbf{z}}^2 \ell$.

Критерии качества оценки

- ▶ Верхняя граница должна выполняться для любых допустимых конфигураций.
- ▶ При масштабировании (рост E или K) граница должна убывать вместе с эмпирической нормой.

Theorem (Основной результат)

Пусть $\|\mathbf{x}\|_2 \leq M_{\mathbf{x}}$, $\|\mathbf{A}\|_2 \leq M_{\mathbf{A}}$, $\|\mathbf{W}_e^{(1)}\|_2 \leq M_1$, $\|\mathbf{W}_e^{(2)}\|_2 \leq M_2$ для всех e , и $S_g(\mathbf{x}) = \sum_{e=1}^E g_e(\mathbf{x})^2$. Тогда для softmax-гейтинга

$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 S_g(\mathbf{x}) (M_1^2 + M_2^2 + 4M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Следствие для top- K

Для разреженного гейтинга (top- K , затем softmax на K экспертах) оценка сохраняется с заменой S_g на $\sum_{e \in \mathcal{T}} \tilde{g}_e^2$.

Примечание: Если не учитывать S_g , получается более простая граница:


$$\|\mathbf{G}(\mathbf{w})\|_2 \leq M_{\mathbf{A}} M_{\mathbf{x}}^2 (M_1^2 + M_2^2 + M_1^2 M_2^2 M_{\mathbf{x}}^2).$$

Цели вычислительного эксперимента

1. Проверить справедливость теоретической оценки на синтетических данных в сценарии «учитель–ученик».
2. Сравнить улучшенную оценку (с S_g) с грубой оценкой (без S_g).
3. Оценить, насколько верхняя граница близка к реальной норме.
4. Проверить, сохраняется ли зависимость от S_g в более сложной архитектуре (ViT + MoE на MNIST).

Эксперимент «учитель–ученик» (часть 1)

Модель	МоЕ-слой (softmax-гейтинг), $d=16$, $d_{\text{ff}}=32$, E варьируется
Сценарий	«Учитель–ученик»: фиксированная и обучаемая модели одной архитектуры; ученик учится предсказывать выходы учителя
Данные	Синтетические: 2048 обуч. / 512 тест.
Функция потерь	$\frac{1}{2}\ \mathbf{z} - \mathbf{y}\ _2^2$ ($\mathbf{A} = \mathbf{I}$, $M_{\mathbf{A}} = 1$)
Метрики	$\ \mathbf{G}\ _2$, улучшенная граница B_{S_g} , грубая граница B_0




Сравнение $\|\mathbf{G}\|_2$ и верхних оценок


Анализ:

- ▶ Оценка с S_g убывает вместе с $\|\mathbf{G}\|_2$.
- ▶ Оценка без S_g — константа, не отражает масштабирование.
- ▶ Почему $S_g \approx 1/E$? При инициализации и в симметричном сценарии softmax почти равномерен.
- ▶ Следовательно, граница $\sim 1/E$ — объясняет убывание.

Эксперимент «учитель–ученик» (часть 2)



Отношение $\|\mathbf{G}\|_2$ к границам



S_g от E (пунктир — $1/E$)

Вывод: Грубая оценка B_0 не отражает масштабирование.

Отношение $\|\mathbf{G}\|_2/B_{S_g}$ стабилизируется, $S_g \approx 1/E$ определяет убывание границы.

Эксперимент 2: ViT+MoE на MNIST

Архитектура


ViT с одним трансформерным блоком, FFN заменён на MoE
($d = 16$, $d_{\text{ff}} = 64$)

Данные


MNIST (обучение 5 эпох, Adam, lr 10^{-3})

Измерения

$\|\mathbf{G}\|_2$ (только по параметрам MoE-слоя) и среднее S_g на тесте



$\|\mathbf{G}\|_2$ и S_g от E (пунктир — $E^{-0.75}$)



Отношение $\|\mathbf{G}\|_2 / S_g$

1. Получена явная верхняя оценка спектральной нормы гаусс-ньютоновской компоненты гессиана для слоя МоЕ.
2. Оценка содержит множитель $S_g = \sum g_e^2$ и **не содержит явного множителя E** .
3. Для разреженной top- K маршрутизации оценка сохраняется с заменой S_g на сумму квадратов весов активных экспертов.
4. Эксперименты на синтетике и MNIST подтверждают: S_g определяет масштабирование $\|\mathbf{G}\|_2$ при росте E .
5. Результаты создают основу для анализа стабилизации ландшафта при масштабировании МоЕ-моделей.