

One-slide talk

Mixture of experts: $\mathbf{z} = \sum_{e=1}^E g_e(\mathbf{x}) \text{FFN}_e(\mathbf{x})$, $\text{FFN}_e(\mathbf{x}) = \mathbf{W}_e^{(2)} \text{ReLU}(\mathbf{W}_e^{(1)} \mathbf{x} + \mathbf{b}_e^{(1)}) + \mathbf{b}_e^{(2)}$

Гейтинг: $g_e(\mathbf{x}) = \frac{\exp(\mathbf{a}_e^\top \mathbf{x} + b_e)}{\sum_j \exp(\mathbf{a}_j^\top \mathbf{x} + b_j)}$ (softmax) или top- K . Параметры $\mathbf{w} = (\mathbf{w}_{\text{exp}}, \mathbf{w}_a)$.

Разложение Гессе:

$$\mathbf{H} = \mathbf{G} + \mathbf{R}, \mathbf{G} = \mathbf{J}^\top \mathbf{A} \mathbf{J}$$

Блочная факторизация:

$$\mathbf{G}^{(p,q)} = \mathbf{P}^{(p)\top} \mathbf{S}^{(p)\top} \mathbf{A} \mathbf{S}^{(q)} \mathbf{P}^{(q)}$$

Цель: верхняя оценка $\|\mathbf{G}\|_2$ для MoE.

